

電気使用量予測のための深層学習手法

6 月 15 日 (火)

小松 大起

1 はじめに

1.1 研究背景

電力発電においてコストは我々消費者だけでなく、2011 年 3 月 11 日に発生した東日本大震災以降、原子力発電は安全性に問題があるとされ 2021 年 5 月現在では停止中の 2 基も合わせて合計 9 基の原子力発電所が稼働するのみとなっている。

近年、情報処理技術として知的処理技術の一つである深層学習が様々な分野で用いられている。深層学習とは、ニューロンの層が多段に組み上げられたニューラルネットワークのことを指す。[1] ニューラルネットワークとは人間の脳の仕組みから着想を得たものであり、神経回路網をコンピュータ上で表現しようと作られた数理的モデルである。深層学習で用いられる分野としては株価予想や人物認識や表情認識、擬似的なデータを生成するアルゴリズムである GAN を用いた画像生成などに挙げられる画像処理、話し言葉や書き言葉など我々が普段使うような自然言語を対象として、これらの言葉が持つ意味を解析する自然言語処理などがある。

1.2 研究目的

電気使用量は人間の認知は時間経過による視覚世界の変化の予測が可能である。近年では実際に予測動画を作る研究も行われてきている。[2] 電力使用量を予測することによる、電気料金の予測が可能になると考えられる。本研究では、電力使用量を主データとし、天気や気温が与える電力使用量の変化を考慮した電気使用量の予測を行うことを目的とする。

2 深層学習モデル

2.1 RNN

2.2 LSTM

3 活性化関数

活性化関数とは、ニューロン間の移動に伴い入力値を別の数値に変換して出力するための関数のことである。

3.1 ステップ関数

ステップ関数は、入力が 0 未満の場合には常に出力値が 0 となり、0 以上の場合には常に出力値が 1 となるような関数を指す。ステップ関数は、パーセプトロンから用いられている関数であり入力 0 を起点として階段状のグラフを示す。この起点を閾値と呼ぶ。入力を x として $f(x)$ を出力とすると数式は以下の式で表される。

$$f(x) = \begin{cases} 0, & (x < 0) \\ 1, & (x \geq 0) \end{cases} \quad (1)$$

4 事前実験

4.1 用いるモデル構造

本実験では、RNN 及び LSTM を用いて電力使用量の予測を行う。また、予測に用いるデータは電力使用量のみを用いる。本実験では、予測結果は全て $t+1$ ステップ後の結果を表している。

4.2 用いるデータ

本実験で用いるデータは、東京電力パワーグリッド株式会社が提供している 2016 年 4 月から 2020 年 12

月までの電力使用量のデータであり、年度、日にち、1時間ごとの電力使用量（万 Kw）の3要素が csv ファイルで提供されている。2016 年は 4 月からのデータのため、6600rows * 3columns, 2017 年から 2019 年は 8760rows * 3columns, 2020 年は閏年であり通常よりも 1 日分多いため 24 列多い 8784rows * 3columns のデータである。また、用いるデータの一例を図 0 に示す。これらのデータの日にちと時間を結合させて日時のデータとする。また、その際に日付と時間が並んでいるだけの文字列であるので、Python のデータ解析用ライブラリである pandas を用いて文字列を日付データに変換する。その例を図 0 に示す。また、データを可視化してグラフにしたものの例として 2019 年、2020 年のグラフ及び、2020 年 4 月の 5 日から 11 日、12 日から 18 日、19 日から 25 日の 3 週分のグラフをそれぞれ図に示す。2019 年、2020 年のグラフからわかることは夏と冬に電力使用量のピークを迎え、春と秋に使用量は減っていることがわかる。時間帯によっても使用料の増減があることが日のグラフを見ることでわかる。深夜から朝にかけて段々と使用料が増えていき、人々が活動を行なっているであろう 9 時ごろから 18 時ごろまで使用量がピークで、そこから使用量が段々と下がっていることがわかる。また、電力使用量に関しては全てのデータの平均でそれぞれのデータを割って正規化を行なったものを入力データとして扱う。

4.2.1 RNN

keras の simpleRNN というモデルを用いて訓練データと試験データを 8:2 に分けて学習データの作成を行った。中間層 1 層、隠れニューロン数は 100 とした。また、その時の予測の結果を図 0 に示す。

4.2.2 LSTM

RNN と同条件で予測を行った結果を以下の図に示す。

4.3 予測結果

それぞれのモデル構造における Train loss 及び、Test loss を以下の表に示す。結果から、電気使用量のみを学習させた場合にも大まかな予測ができていくことがわかる。

Tab. 1: 天気概況による数値付け

天気概況	対応する数値
「快晴」	0.0
「晴」	0.0
「曇」	0.
「薄雲」	0.
「大風」	0.5
「霧」	0.
「霧雨」	0.
「雨」	1.0
「大雨」	1.0
「暴風雨」	1.0
「みぞれ」	1.0
「雪」	1.0
「大雪」	0.
「暴風雪」	0.
「地ふぶき」	0.
「ふぶき」	0.
「ひょう」	0.
「あられ」	0.
「雷」	0.
「×」	0.

5 用いる追加データ

本研究では、電力使用力の予測を天気、気温などの外的要因から行うことを目的とする。国土交通省の気象庁がホームページで公開している気温、天気の情報を用いる。また、そのデータの例を図 0 に示す。天気予報による天気の予測と実際の電気使用量の関連性を調べる。天気概況をグラフに示す。品質番号は 8 を最大として利用上注意が必要がどうかを示す値である。均質番号は番号により観測環境の違いを表している。この値が違う場合には、同列のデータとして扱うことは難しい。

6 今週の作業

- 晴れ「0.0」、雨「1.0」として天気に数値をつける。
-

- ☒天気, 気温, 降水量の影響が大きいことがわかったため, これらの要素を加えた予測を行う.

7 来週以降の作業

•

8 参考文献

[1] 浅川伸一. python で体験する深層学習. コロナ社, 2016. [2]William Lotter, Gabriel Kreiman, David Cox, “Deep Predictive Coding Networks for Video Prediction and Unsupervised Learning” , ICLR, 2017

2018/1/1 18:10 UPDATE

DATE, TIME, 実績(万kW)
2016/4/1,0:00,2555
2016/4/1,1:00,2433
2016/4/1,2:00,2393
2016/4/1,3:00,2375
2016/4/1,4:00,2390
2016/4/1,5:00,2467
2016/4/1,6:00,2631
2016/4/1,7:00,2775
2016/4/1,8:00,2965
2016/4/1,9:00,3159
2016/4/1,10:00,3211
2016/4/1,11:00,3265
2016/4/1,12:00,3160
2016/4/1,13:00,3288
2016/4/1,14:00,3361
2016/4/1,15:00,3362
2016/4/1,16:00,3406
2016/4/1,17:00,3438
2016/4/1,18:00,3501
2016/4/1,19:00,3381
2016/4/1,20:00,3242
2016/4/1,21:00,3084
2016/4/1,22:00,2973
2016/4/1,23:00,2811
2016/4/2,0:00,2613
2016/4/2,1:00,2492

Fig. 1: 用いる電力使用量データ例




Fig. 2: 2019 年の電力使用量のグラフ




Fig. 3: 2020 年の電力使用量のグラフ

	東京	東京	東京	東京	東京	東京
年月日	天気概況(昼：06時～18時)	天気概況(昼：06時～18時)	天気概況(昼：06時～18時)	天気概況(夜：18時～翌日06時)	天気概況(夜：18時～翌日06時)	天気概況(夜：18時～翌日06時)
		品質情報	均質番号		品質情報	均質番号
2020/4/13	大雨	8	1	雨後一時晴	8	1
2020/4/14	快晴	8	1	快晴	8	1
2020/4/15	薄曇一時晴	8	1	薄曇	8	1
2020/4/16	曇	8	1	曇時々雨	8	1
2020/4/17	曇時々晴	8	1	曇後雨	8	1
2020/4/18	大雨	8	1	晴一時曇	8	1
2020/4/19	晴	8	1	曇後時々雨	8	1
2020/4/20	雨	8	1	曇時々晴	8	1
2020/4/21	曇	8	1	曇時々晴	8	1
2020/4/22	晴後曇時々雨	8	1	曇時々雨	8	1
2020/4/23	晴時々薄曇	8	1	晴後時々薄曇	8	1
2020/4/24	晴一時曇	8	1	晴一時雨	8	1
2020/4/25	快晴	8	1	快晴	8	1
2020/4/26	薄曇時々晴	8	1	曇	8	1
2020/4/27	曇後雨	8	1	雨後晴時々曇	8	1
2020/4/28	曇後一時雨、雷を伴う	8	1	曇時々晴	8	1
2020/4/29	快晴	8	1	快晴	8	1
2020/4/30	晴	8	1	快晴	8	1
2020/5/1	晴時々薄曇	8	1	快晴	8	1
2020/5/2	快晴	8	1	晴後一時薄曇	8	1
2020/5/3	曇	8	1	曇時々雨	8	1
2020/5/4	雨後曇	8	1	晴時々曇	8	1
2020/5/5	曇時々晴	8	1	曇後時々雨	8	1
2020/5/6	曇時々雨、雷を伴う	8	1	曇時々雨、雷を伴う	8	1
2020/5/7	晴	8	1	晴後時々薄曇	8	1
2020/5/8	晴一時曇	8	1	薄曇時々晴	8	1
2020/5/9	曇	8	1	曇時々雨	8	1
2020/5/10	曇時々雨	8	1	曇一時雨	8	1

Fig. 4: 東京都における天気データ例

天気概況用語	大気の状態
「快晴」	雲量1以下の状態が長く継続している状態。
「晴」	雲量2以上8以下の状態。
「曇」	雲量9以上であり、中・下層雲量が上層雲量よりも多く、降水現象がない状態。
「薄曇」	雲量9以上であり、上層雲量が中・下層雲量よりも多く、降水現象がない状態。
「大風」	10分間平均風速が15.0m/s以上の風を観測した場合。
「霧」	大気中に浮遊するごく小さな水滴を観測し、水平視程が1km未満の場合。
「霧雨」	きわめて多数の細かい水滴だけがかなり一様に降る降水を観測した場合。
「雨」	雨を観測した場合。
「大雨」	「雨」の場合で、特に降水量が30.0mm以上の状態。
「暴風雨」	「大雨」かつ「大風」を観測した場合。（「大雨、大風を伴う」のように用いることはありません。）
「みぞれ」	雨と雪とが混在して降る降水を観測した場合。
「雪」	雪を観測した場合。
「大雪」	「雪」の場合で、北海道、青森、秋田、盛岡、山形、新潟、金沢、富山、長野、福井、鳥取、松江においては当該時間帯の降雪の深さが20cm以上であった場合。また、それ以外の地域においては降雪の深さが10cm以上であった場合。
「暴風雪」	「大雪」かつ「大風」を観測した場合。（「大雪、大風を伴う」のように用いることはありません。）
「地ふぶき」	積もった雪が風のために空中に吹き上げられ、かつそれにより視程が1km未満の状態。
「ふぶき」	「地ふぶき」かつ「雪」を観測した場合。
「ひょう」	直径5mm以上の氷の粒またはかたまりの降水を観測した場合。
「あられ」	直径が概ね5mm未満の白色不透明・半透明または透明な氷の粒の降水を観測した場合。
「雷」	雷電または強度1以上の雷鳴のいずれかを観測した場合。
「×」	何らかの理由（煙霧による視程障害等）により、雲の状態が不明で、天気概況が不明または欠測である場合。

Fig. 5: 天気概況用語一覧




Fig. 6: RNN の結果例