

電気使用量予測のための深層学習手法

11 月 16 日 (火)

小松 大起

1 はじめに

1.1 研究背景

2011 年 3 月 11 日に発生した東日本大震災以降, 低コストかつ効率的な発電方法であり全体の 2 割から 4 割を占めていた原子力発電は安全性に問題があるとされ 2021 年 5 月現在では停止中の 2 基も合わせて合計 9 基の原子力発電所が稼働するのみとなっている [1]. それにより, 原子力発電よりコストの高い火力発電での発電量が増え発電コストの増加による電気料金の値上げが生じ, 我々消費者の負担増加に繋がっている [2].

1.2 研究目的

電気使用量は人間の認知は時間経過による視覚世界の変化の予測が可能である. 近年では実際に予測動画を作る研究も行われてきている.[sankou2] 電力使用量を予測することによる, 電気料金の予測が可能になると考えられる. 本研究では, 電力使用量を主データとし, 天気や気温が与える電力使用量の変化を考慮した電気使用量の予測を行うことを目的とする.

2 深層学習モデル

3 実験

3.1 用いるモデル構造

3.2 用いるデータ

3.2.1 RNN

3.2.2 LSTM

3.3 予測結果

4 修論

修論 20 % 8 枚

1 はじめに 40 %

1.1 研究背景 50 %

1.2 研究目的 30 %

2 機械学習手法について 2 %

2.1 教師あり学習手法 0 %

2.2 教師なし学習手法 0 %

2.3 形式ニューロン 0 %

2.4 順伝播型ニューラルネットワークモデル 0 %

2.5 誤差逆伝播法 0 %

2.6 CNN 80 %

2.7 RNN 80 %

2.8 LSTM 80 %

2.9 深層学習モデルを用いたマルチモーダル予測 0 %

3 用いるデータについて 80 %

3.1 電力使用量 90 %

3.2 気温 90 %

3.3 降水量 90 %

3.4 天気 90 %

3.5 各データ間の関係性 70 %

3.5.1 相関係数 70 %

3.5.2 相互情報量 70 %

4 電力使用量予測のための深層学習 0 %

4.1 RNN による予測 0 %

4.2 LSTM による予測 0 %

4.3 一様な多入力予測 0 %

4.4 構造化多入力による予測 0 %

5 実験結果 0 %

6 考察 0 %

7 まとめ 0 %

7.1 まとめ 0 %

7.2 今後の課題 0 %

5 先週の作業

- 相互情報量を求めた。相関係数は非線形な関係をもとめられないのに対して相互情報量は非線形な関係も求めることができるので値が大きいことがわかった。

6 今週の作業

- 外れ値の検出について考える。その季節では外れ値であっても他の季節では普通の値なので平均や四分位範囲での検出ができない。日にち単位で考えると 1 日だけ増えているように見えるが時間単位だと数時間の電力使用量の増加になっているため、外れ値の検出が難しい。
- 指数加重移動平均という時系列データにおいて古いデータの影響が弱くなっていくという外れ値の検出を試してみたい。
- 外れ値の検出を行うには、予測結果が必要だが予測精度だけを調べて詳細な予測の値を保存していないのもう一度結果を求める必要がある。
- 以前の rnn の予測精度結果の評価指標が違うので予測やり直す。層数と素子数の組み合わせも少なかったなので、地方会以後のものに合わせる。

Tab. 1: 電力使用量と各項目の期間ごとの相関係数

	気温	降水量	天気
時間	0.085	-0.024	-0.014
日付	-0.069	-0.069	-0.13
週	-0.075	-0.20	-0.050

Tab. 2: 電力使用量と気温の平均からの差の絶対値との相関係数

	気温
時間	0.555
日付	0.798
週	0.905

- 予測結果を保存できるようになったので、これで外れ値検出して予測に用いたい。

Tab. 3: 電力使用量と各項目の期間ごとの相互情報量

	気温	降水量	天気
時間	0.438	0.0423	0.0346
日にち	0.851	0.419	0.284
週	0.999	0.889	0.643

Tab. 4: 電力使用量と気温の平均からの差の絶対値との相互情報量

	気温
時間	0.438
日付	0.851
週	0.999

参考文献

- [1] 経済産業省・資源エネルギー庁, 日本の原子力発電所の状況, 2021.
- [2] 松尾 雄司, 永富 悠, 村上朋子, 有価証券報告書を用いた火力・原子力発電コスト構造の分析, Journal of Japan Society of Energy and Resources, Vol. 33, No. 5
- [3] 鎌田 真, 市村 匠, リカレント構造適応型 Deep Belief Network による時系列データの学習, 計測自動制御学会論文集, Vol.54, No.8, 628/639(2018).
- [4] 浅川伸一. python で体験する深層学習. コロナ社, 2016.
- [5] Sepp Hochreiter; Jürgen Schmidhuber (1997). Long short-term memory. Neural Computation 9 (8): 1735 – 1780.
- [6] Williams, Ronald J.; Hinton, Geoffrey E.; Rumelhart, David E. (October 1986). Learning representations by back-propagating errors. Nature 323 (6088): 533 – 536. doi:10.1038/323533a0. ISSN 1476-4687.