

構造化ニューラルネットワークの新しい学習法と 最大電力需要予測への適用

正員 飯坂 達也* 正員 松井 哲郎*
正員 福山 良和*

A New Training Method for Analyzable Structured Neural Network and Application of Daily Peak Load Forecasting

Tatsuya Iizaka*, Member, Tetsuro Matsui*, Member, Yoshikazu Fukuyama*, Member

This paper presents a daily peak load forecasting method using an analyzable structured neural network (ASNN) in order to explain forecasting reasons. In this paper, we propose a new training method for ASNN in order to explain forecasting reason more properly than the conventional training method. ASNN consists of two types of hidden units. One type of hidden units has connecting weights between the hidden units and only one group of related input units. Another one has connecting weights between the hidden units and all input units. The former type of hidden units allows to explain forecasting reasons. The latter type of hidden units ensures the forecasting performance. The proposed training method make the former type of hidden units train only independent relations between the input factors and output, and make the latter type of hidden units train only complicated interactions between input factors.

The effectiveness of the proposed neural network is shown using actual daily peak load. ASNN trained by the proposed method can explain forecasting reasons more properly than ASNN trained by the conventional method. Moreover, the proposed neural network can forecast daily peak load more accurately than conventional neural network trained by the back propagation algorithm.

キーワード：電力需要予測，ニューラルネットワーク，構造化学習，説明

Keywords: load forecasting, neural networks, structured learning, explaining

1. まえがき

近年の情報化社会の進展に伴い，社会の電力エネルギーへの依存度が増大しており，信頼性の高い電力供給が求められている。しかし，現状では大容量の電力貯蔵は困難であるため，高品質，高信頼度な電力供給を効率的に行うためには，予め予測した電力需要に基づいて需給運用計画を立案する必要がある。

このように電力需要予測は電力の安定供給，及び経済運用のために非常に重要な役割を果たしている。特に，翌日，当日における1日の最大電力の予測は電力供給の信頼性，経済性に大きな影響を与えるため，高い予測精度が要求される。

このような電力需要予測に対し，従来から気象と電力需要の感度式や過去事例を参考にして，さらに熟練運用者の経験的判断を加えた予測が行われている。しかし，熟練運用者の減少，運用者の負担軽減等の背景から，より高精度かつ予測理由の説明ができる予測手法の開発が求められている。

最大電力の予測手法は，従来から重回帰分析に代表される統計的手法による予測手法や，ニューラルネットワークによる予測手法の研究が行われ，高精度な予測システムが開発され，実用化例も報告されてきている^{(1)~(4)}。

しかしながら，重回帰式は十分な予測精度をもつ非線形モデルの構築に時間がかかり，ニューラルネットワークは予測理由を説明することは困難である欠点があった。

近年，予測理由の説明が可能なニューラルネットワークとして，石川，福見による忘却付き構造学習⁽⁸⁾⁽¹¹⁾が提案された。しかし，これらの方法は離散値出力の問題に適用範囲が限られ電力需要予測に対して適用することはできない。

電力需要予測において予測理由を説明する研究としては，

* 富士電機（株）事業開発室
〒191-8502 日野市富士町1番地
Corporate Technology Development Office, Fuji Electric Co., Ltd.
1, Fuji-machi, Hino 191-8502

学習機能を持つファジー推論を用いる手法⁽¹²⁾、2進木とニューラルネットワークを融合する手法⁽¹³⁾がある。学習機能を持つファジー推論手法は、数入力程度の少ない入力因子を用いて予測し、If-then形式で予測値を説明する方法である。2進木とニューラルネットワークを融合する手法は、2進木部分にてIf-Then形式で予測値の説明を行い、ニューラルネットワーク部分で最終的な予測値を出力する方法である。いずれの手法ともIf-Then形式で予測値を説明することが可能であり、運用者にとって分かりやすい説明方法であるといえる。

筆者らは、これまでの電力需要予測の研究を通して運用者が気温1°Cあたりの電力需要の変化量（以下感度と表記）を重要視していることを認識し、この運用者が重要視している感度を用いて予測値を説明する1手法として構造化ニューラルネットワークを提案した⁽⁵⁾⁻⁽⁷⁾。構造化ニューラルネットワークは、多層パーセプトロン的一种であり、任意の入力因子群だけと結合する疎結合と呼ばれるサブネットワークと、全ての入力因子と結合する全結合と呼ばれるサブネットワークから成り立つ。疎結合部分で任意の入出力因子群と出力因子の独立した非線形な関係を学習し、全結合部分で入力因子間の複雑な相互作用分と出力因子の関係を学習することで、疎結合部分が入力因子の大きさにより異なる感度の変化を用いた予測理由の説明を行い、全結合部分が予測精度を保証することが可能になる。つまり、構造化ニューラルネットワークは、電力需要予測において気象と電力需要の感度を用いた説明が重視される場合に有効な方法である。

しかし文献⁽⁵⁾⁻⁽⁷⁾で提案した学習方法では疎結合と全結合を役割に応じて明確に学習できるとは限らなかった。つまり、任意の入力因子群と出力因子の独立した関係が必ずしも疎結合部分だけで学習されるわけではなく、しばしば全結合部分で学習されることがある。その結果、常に適切な予測理由の説明が行えるとは限らなかった。

本論文では、構造化ニューラルネットワークの新しい学習方法を提案し最大電力需要予測に適用した。また、既提案学習手法による構造化ニューラルネットワークとの予測説明能力の比較、バックプロパゲーション法（BP法）で学習した従来の多層パーセプトロンとの学習誤差の比較を行ったので報告する。

新規に提案する学習法で学習した構造化ニューラルネットワークを解析した結果、複数ある入力因子群と出力因子である翌日最大電力需要の非線形な相関関係を既提案学習方法で学習した構造化ニューラルネットワークよりも適切に学習しており、予測理由の適切な説明が可能であることを確認した。また、バックプロパゲーション法で学習した従来の多層パーセプトロンと同等以上の予測精度であることを確認した。

2. 構造化ニューラルネットワーク⁽⁵⁾⁻⁽⁷⁾

構造化ニューラルネットワークの原理説明のために、回

帰式、従来の多層パーセプトロン、構造化ニューラルネットワークの写像関数例を示す。次式は入力因子が x_1, x_2 の2つである場合の例である。

回帰式の写像関数例

$$f(x) = ax_1 + bx_2 + c \cdots \cdots (1)$$

ここで a, b, c ：回帰係数

従来の多層パーセプトロンの写像関数例

$$f(x) = f(x_1, x_2) \cdots \cdots (2)$$

構造化ニューラルネットワークの写像関数例

$$f(x) = g(f_1(x_1) + f_2(x_2) + f_3(x_1, x_2)) \cdots \cdots (3)$$

ここで $g()$ ：出力層シグモイド関数、 $f_1(), f_2(), f_3()$ ：学習により抽出される非線形関数

回帰式の最大の利点は、(1)式のように入力因子ごとに独立した感度（係数）を持つため、予測理由の説明能力に優れている点である。一方、従来の多層パーセプトロンは、(2)式のように全ての入力因子が相互に影響し合うため、感度解析による説明もある微小空間に限定される欠点がある。構造化ニューラルネットワークは、回帰式のように入力因子ごとに独立して出力との関係が説明可能であるため、予測理由の説明能力が高い利点を持つ。(3)式の例では、入力因子ごとの非線形関数 $f_1() \sim f_3()$ にて増減傾向の定性的説明が可能である。特に、出力層のシグモイド関数 $g()$ の線形領域だけが用いられている場合には、非線形関数 $f_1() \sim f_3()$ を用いて定量的な説明が可能である。

以下に構造化ニューラルネットワークの構造的特徴と予測理由の説明法について述べる。また、生成方法については第3章で説明する。

構造化ニューラルネットワークの概念を図1に示す。構造化ニューラルネットワークは、複数のサブネットワーク構造を持ち、任意の入力因子グループだけと結合する中間層素子（疎結合部分）と全ての入力因子と結合する中間層素子（全結合部分）より構成される。疎結合のサブネットワークは、任意グループと出力との独立した関係を表しており、任意グループごとの解析が可能である。全結合のサブネットワークは、入力グループ間の相互作用を表し、従来のニューラルネットワークと同等の性能を保証する。

構造化ニューラルネットワークの予測理由の説明法を以下の2次関数を例題にして具体的に説明する。

$$y = x_1 + x_2 + x_1x_2$$

$$x_1, x_2 = \{0.0 \sim 1.0\}$$

構造化されたニューラルネットワークの一例を図2に示す。図2の結合状態は、1, 2番目の中間層素子は x_1, x_2 の独立した成分の存在を示唆し、3番目の中間層素子は x_1, x_2 の相互作用の存在を示唆している。

図3に学習により得られたニューラルネットワークの入出力特性を示す。1, 2番目の中間層素子は線形かつほぼ同




図 1 構造化ニューラルネットワーク構造

Fig. 1. Structure of ASNN.




図 2 2 次関数学習後の構造

Fig. 2. Structure of a trained neural network for the quadric function.




図 3 2 次関数を学習したニューラルネットの入出力特性

Fig. 3. Input/output relations of a trained neural network for the quadric function.

値，3 番目の中間層素子は 2 次の関係である。これは関数の各項の特性そのものである。このように，入出力特性を解析することで，各入力因子ごとに独立して出力との関係を求めることができる。この事により，以下に示す説明が容易に実現できる。

(1) 出力に対する各入力因子の貢献度合いを説明することができる。例えば，電力需要予測において気温と過去の電力実績値の影響度合いを明確にできる。

(2) 入力因子が変動した場合の予測値の変化方向が他の入力因子に影響されことなく説明できる。例えば，予測対象日の気温が気象予報値よりも高かった場合に，電力需要が増加するのか減少するのか説明できる。特に出力因子を 0.4～0.6 に正規化するなどしてシグモイド関数の線形

領域を用いる場合には，入力因子の大きさによる感度変化の違い，例えば気温帯による気温と電力需要の感度変化の違いを定量的に説明することができる。

(3) ニューラルネットワークの学習状態を入出力特性より説明することができる。例えば，学習データ分布と異なる関係が表れれば不適切な学習状態と言える。

例題のような 2 変数程度の関数では，全結合の中間層素子の特性も (x_1, x_2 , 出力層の入力値) の張る 3 次元空間にプロットすることで予測理由の説明が可能になるが，入力変数が多くなると予測理由の説明は困難になる。これがニューラルネットワークがブラックボックスであると言われる理由である。それゆえ，構造化ニューラルネットワークは，疎結合部分が予測説明機能を，全結合部分が予測精度を保証する機能分担している。

以下 3 章に，構造化ニューラルネットワークの学習方法について述べる。

3. ニューラルネットワークの学習法

3.1 不要素子を削除するための定式化⁽⁵⁾⁻⁽⁷⁾ 不要な中間層素子や結合があると解析や予測結果の説明が容易でなく，汎化能力低下の原因にもなる。構造化ニューラルネットワークは，忘却付き構造学習⁽⁸⁾，重畳エネルギー関数⁽⁹⁾，コンパクト構造化法⁽¹⁰⁾を併用することで，不要素子の削除を実現している。

重畳エネルギー関数は，複数の部分パーセプトロンを定義し，番号の小さい部分パーセプトロンの結合は相対的に早く成長させ，番号の大きい部分パーセプトロンの結合は相対的に遅く成長させる方法である。これにより必要な素子は大きく成長し，不要な素子の成長は抑制される。忘却付き構造学習は，評価関数に重みの絶対値和の項を付加することで，不要な結合を小さくさせる方法である。2 つのアルゴリズムを併用したエネルギー関数を次式に示す。

$$F = \sum_i^H \beta_i E_i + \varepsilon' \sum |\omega_{ij}| \dots \dots \dots (4)$$

$$E_i = \frac{1}{2} (y_t - y_i)^2 \dots \dots \dots (5)$$

$$\beta_i = \frac{6i^2}{H(H+1)(2H+1)} \dots \dots \dots (6)$$

ここで， F ：エネルギー関数， H ：部分パーセプトロンの総数， β_i ：正の定数， ε' ：忘却係数， ω ：結合係数， E ：部分パーセプトロンのエネルギー関数， y_t ：教師データ， y_i ：部分パーセプトロンの出力

重みの修正量は次式である。

$$\Delta w_{ij} = -\eta \frac{\partial F}{\partial w_{ij}} = \Delta w'_{ij} - \varepsilon \text{sgn}(w_{ij}) \dots \dots \dots (7)$$

$$\text{sgn}(x) = \begin{cases} -1 & (x < 0) \\ 0 & (x = 0) \\ 1 & (x > 0) \end{cases}$$

ここで、 $\Delta w'_{ij}$ は重畳エネルギー関数による修正量、 η : 学習係数、 ε : 忘却量

上記エネルギー関数使用時には、忘却量 ε の設定が重要になる。もし忘却量 ε が大きすぎると必要な結合までも小さくさせすぎ、忘却量 ε が小さすぎると不要な結合が大きい値のまま残ってしまう。そこで、入力層に乱数を入力する素子を1つ付加し、乱数入力につながる結合を学習終了時までに0にするような値を忘却量にしている。算出式は次式である。ただし、忘却量の発散を防ぐため、残り学習回数が規定回数以下になったら、忘却量を固定する。

$$\varepsilon = \text{avg}(|\text{乱数入力の重み係数}| / \text{残り学習回数}) \dots\dots\dots (8)$$

不要な中間層素子は、コンパクト構造化法を用いて削除する。コンパクト構造化法とは、学習データを想起したときに中間層素子出力の分散が小さいものを不要素子とみなしバイアス項に融合し、中間層素子出力の相関係数が高いものどうしを融合する中間層素子の削除手法である。

これまでの経験上、上記学習アルゴリズムは学習誤差の増大の問題もなく良好に不要中間層素子を削除することが可能である⁽⁵⁾。

3.2 ニューラルネットワークの構造化 構造化ニューラルネットワークの既提案の学習法^{(5)~(7)}では、汎化能力が非常に高いものの期待通りの説明理由が得られないことがある。この原因は疎結合と全結合を同時に学習するため、

疎結合部分に抽出されるべき独立成分が全結合部分に抽出されることがあるからである。そこで、疎結合を学習した後に全結合を追加する新しい学習方法を提案する。

提案する学習法は、4つのステップより成り立つ。以下に各ステップの内容を示す。

[Step 1] サブネットワークの初期化を行う。説明目的に応じて複数の入力因子グループを定義し、任意の入力因子グループだけを入力にもつサブネットワークの結合を乱数にて初期化する。

[Step 2] Step 1 で構築した複数サブネットワークを個別に収束するまで学習する。サブネットワークごとに独立して学習することで、目的とする入力因子群と出力因子の独立した1:1の入出力関係を強く学習することが可能である。この段階で、不要な中間層素子の大部分は前節で説明した学習アルゴリズムにより削除される。

[Step 3] Step 2 で学習した複数のサブネットワークを1つのネットワークに合成して収束するまで再学習を行う。ここで、サブネットワークをそのまま結合すると、中間層素子から出力層素子に伝達する情報が過大になり学習の進行が遅れる原因になる。そこで、中間層 - 出力層素子間の結合係数は、サブネットワークの数で割り、小さな値にする。このステップでは、部分パーセプトロンを定義することができないため、前節の学習アルゴリズムは用いずバックプロパゲーション法を用いる。

[Step 4] 全ての入力因子に結合する複数の全結合素子

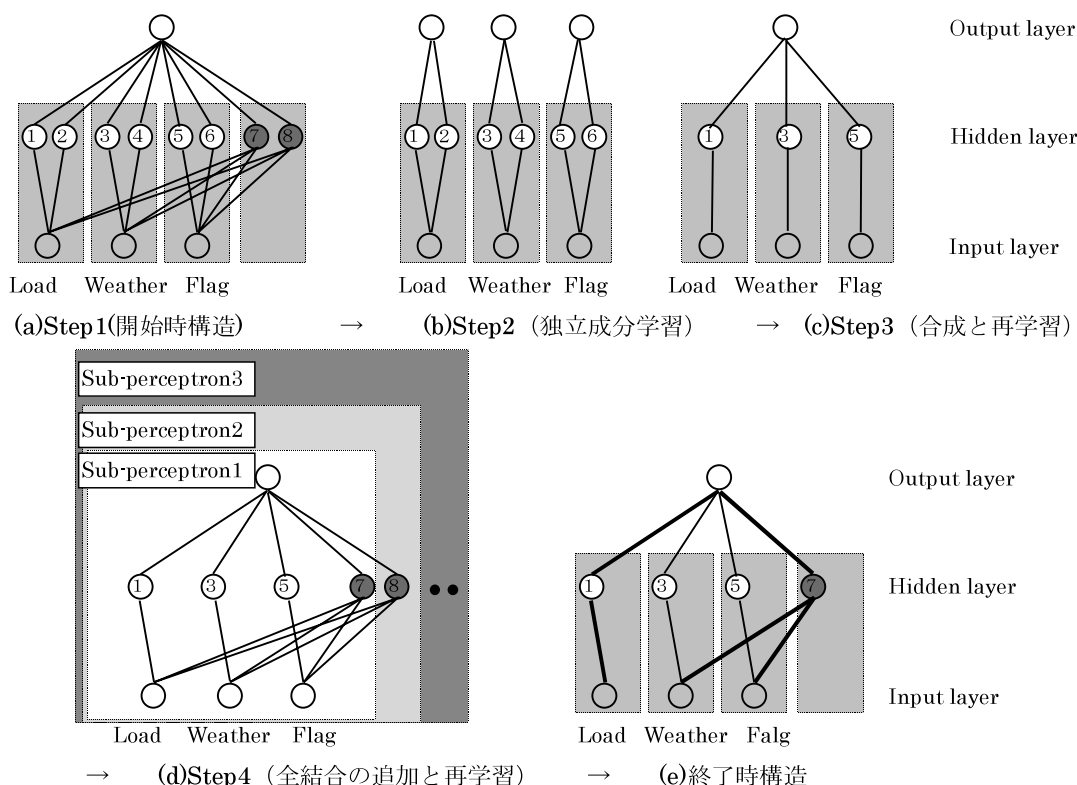


図4 各学習段階の部分パーセプトロン構造

Fig. 4. Structure of a neural network at each learning step.

を追加して再学習を行う。このステップの目的は、疎結合だけでは学習しきれない相互作用分を学習することである。不要な全結合素子の追加を防ぐために、重畳エネルギー関数の概念を利用する。疎結合素子全てと全結合素子1つを部分パーセプトロン1に定義し、その他の全結合素子は1つずつ番号の大きい部分パーセプトロンに定義し再学習を行う。部分パーセプトロンの学習速度の違いと忘却の作用により、不要な全結合素子の生成は抑制される。

3.3 最大電力需要予測問題の構造化例 最大電力需要予測の構造化例を図4を用いて説明する。図4の例では入力因子は過去の電力実績値、気象、特異日を示す3種類であり、出力は翌日の最大電力予測値である。説明目的は、上記3種類の入力因子と出力との入出力相関関係を説明することにする。

説明目的が上記3種類の入出力因子と出力との入出力相関関係の説明であるため、Step 1として図4(a)に示すように3つの入力因子群にサブネットワークを分解している。Step 2として、図4(b)に示すように各サブネットワークを個別に学習する。この段階の学習により、各サブネットワークは、各入力因子と出力因子との独立した関係のみを表すネットワーク構造になるが、学習誤差は非常に大きい。例えば、気温を入力とするサブネットワークは、気温との相関は学習することができるが、平日・休日の最大電力の大きさの違いは考慮できないので誤差は大きい。Step 3として図4(c)に示すように全てのサブネットワークを結合して再学習を行う。この段階の学習誤差は著しく改善されるが、疎結合がない通常の多層パーセプトロンと比較すると誤差が大きいことが多い。Step 4として図4(d)に示すように全結合を追加して再学習を行う。疎結合部分だけでは学習できない相互作用分も学習される。その結果、疎結合部分では任意の入力因子ごとの入出力相関関係が学習され、全結合部分では疎結合では学習しきれない相互作用分が学習される。つまり、過去の電力実績値と出力の関係、気象と出力の関係、特異日と出力の関係が疎結合部分で学習されており、全結合部分でそれ以外の複雑な関係を学習している。

3.4 提案する構造化学習の特徴 回帰式、構造化学習⁽⁸⁾⁽¹¹⁾、構造化ニューラルネットワークの相違点と類似点、及び構造化ニューラルネットワークの新規提案の学習方法と既提案の学習方法⁽⁵⁾⁻⁽⁷⁾の相違点を以下に示す。

(1) 回帰式は、入力因子ごとに感度(係数)を持つため任意の入力因子と出力の関係を個別に説明することができる。構造化ニューラルネットワークは、(3)式で示されるように、入力因子もしくは任意の入力因子グループごとに相関関係が独立しているため、他の入力因子の変化に影響されることなく入力因子と出力の関係を個別に説明することができる。

(2) 忘却付き構造化学習に代表される構造化学習方法⁽⁸⁾⁽¹¹⁾で構築されるニューラルネットワークは、出力が離散値問題に限定される。一方、構造化ニューラルネット

ワークは連続値問題が扱え、電力需要予測問題にも適用可能である。

(3) 構造化ニューラルネットワークの既提案学習方法は、疎結合と全結合を同時に学習させるため、疎結合で学習すべき入出力データの独立成分が全結合部分に抽出されることがある。一方、新規提案学習方法は疎結合と全結合を独立して学習させているため、上記問題の発生する確率が低い。

4. 数値シミュレーション

ここで、新規提案学習方法と既提案学習方法の予測説明機能の比較、及びバックプロパゲーション法による従来の多層パーセプトロンの予測結果の比較を行う。

最大電力需要予測とは、1日の最大電力需要を気象等の因子により予測する問題である。1日の最大電力需要は、気象と非線形の相関関係があり、図6(a)に示すように、気温に対して正と負の相関がある。夏季や冬季は、電力需要が増大するため一般的に予測の重要性は高まるが、気温と電力需要の相関関係は正もしくは負の一方の関係のみであり、規則抽出や説明機能の観点からはむしろ容易な季節であると言える。そのため本論文の主目的である既提案学習

表1 翌日最大電力需要予測問題の入力因子

Table 1. Input data of next day peak load forecasting.

入力グループ	詳細
電力	実績電力(前日), 実績電力(7日前)
最高・最低気温	最高気温(当日~2日前), 最低気温(当日~2日前)
フラグ	休日(当日~2日前), 土曜(当日~2日前)

注) フラグは1, 0の離散値。休日, 土曜のときに1。

表2 学習条件

Table 2. Training conditions.

項目	値・内容	備考
学習回数	各学習ステップで10万回	
忘却量算出	学習9万回目まで, 以降固定	BPでは未使用
中間層素子の融合条件	相関係数0.95以上 分散0.0001未満	BPでは未使用
初期中間層素子数	8	BPでは固定
学習係数	0.1, 0.2, 0.4, 0.6, 0.8	最良値を使用

表3 学習手法の比較

Table 3. Comparison of training methods.

	B P 法	既提案法	提案手法
絶対値平均誤差[%]	2.66	2.39	2.53
絶対値最大誤差[%]	9.30	9.23	8.80
中間層素子数[個]	8	5	5
平均学習時間[sec]	10	39	23

注) Ultra SPARC-II×2 360MHz(SPECint95: 16.1) 使用

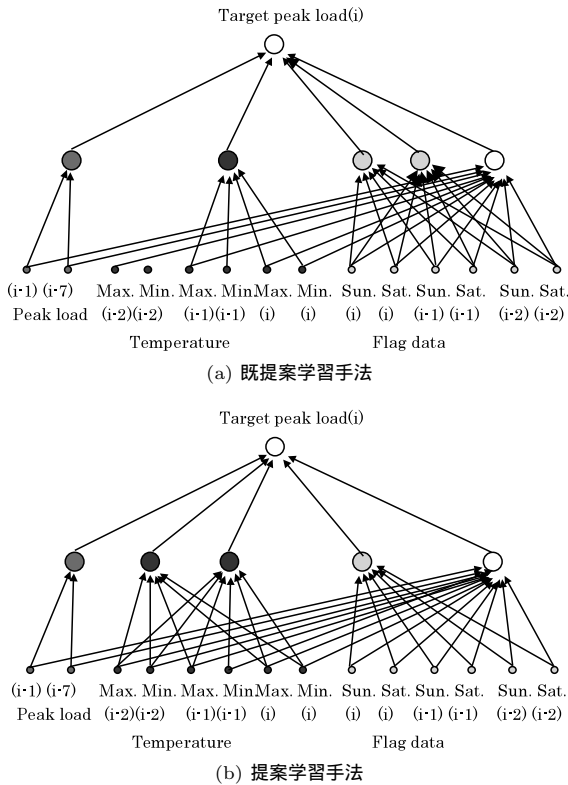


図 5 翌日最大電力予測用ニューラルネットワーク構造

Fig.5. Structure of neural networks for next day peak load forecasting.

法に対する新規学習法の有効性を明確にするため、正負両方の相関が混在し他季節よりも適切な構造学習が難しい春季(4,5月)に構造化ニューラルネットワークを適用する。

予測に使用する入力因子は、過去の適用例⁽²⁾⁽⁴⁾を参考にして表1に示すように決定した。また、入力値全ては0~1に正規化した。出力値は0.1~0.9に正規化し出力層素子のシグモイド関数の非線形領域を用いるようにした。入力因子は14あるが、その性質により3つの入力グループにまとめ、その入力グループごとに解析を行っている。今回の例では3グループごとの解析であるが、より詳細な解析が必要である場合には、より多くのグループに分割することで可能である。予測の精度評価に用いるデータは、春季のデータであり、学習用のデータはその過去3年分の春季データである。学習条件を表2に示す。ここで、各学習手法とも学習係数を5通り変化させ学習データに対する絶対値平均誤差が最小のものを採用した。学習前のニューラルネットワークは、3つの疎結合と1つの全結合に中間層素子を2つずつ配置し、計8の中間層素子を持つ構造である。

図5に学習後の結合状態を示す。既提案学習法でも新規提案学習手法でも3つの中間層素子が削除され5つになっている。

図6に学習データを、図7に学習で獲得した入出力特性を示す。ここで、図7の縦軸は、出力層への入力値であり直感的に分かりづらい値になっているが、出力値を0.4~

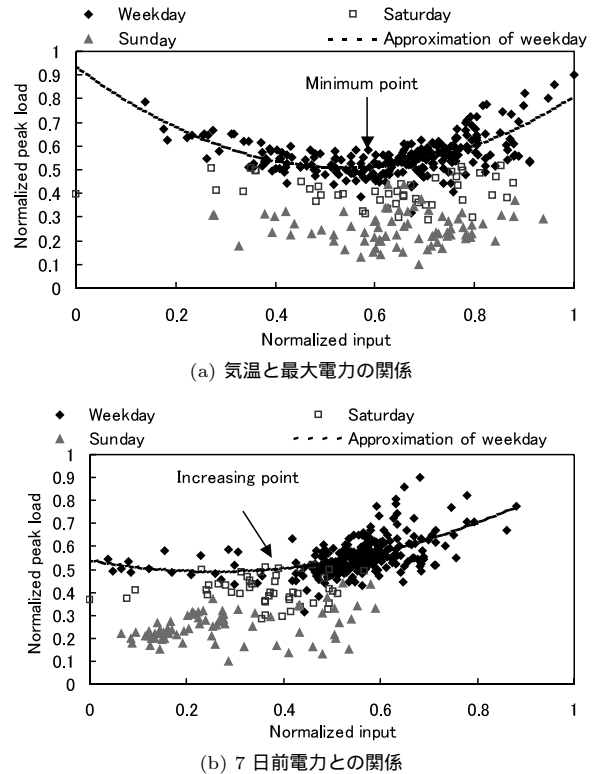


図 6 翌日最大電力需要予測の学習データ

Fig.6. Training data for next day peak load forecasting.

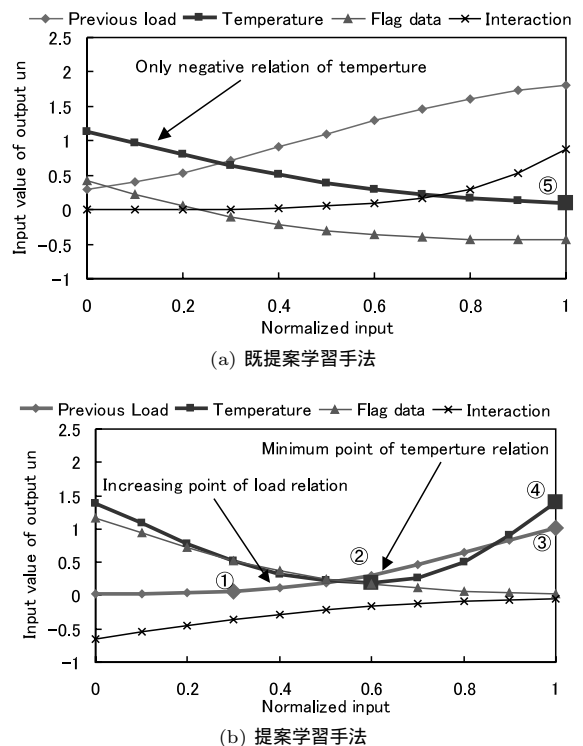


図 7 翌日最大電力需要予測問題の入出力特性

Fig.7. Input/output relations of the trained neural network for next day peak load forecasting.

0.6 に正規化しシグモイド関数の線形領域を用いれば電力値 (MW 換算等) で表すこともでき、直感的に分かりやすい説明も可能である。

図 7(b) に示す提案手法の入出力特性は、気温が入力値約 0.6 を極小値とする 2 次の関係、実績電力が入力値 0.4 付近から急増する関係であり、図 6 に示す学習データの分布とほぼ同じ形状である。また、フラグの入出力特性は、0 (平日) のときに大きく、1 (土曜や休日) のときに小さくなることを示しており、学習データと一致している。一方、図 7(a) に示す既提案学習手法では、気温と電力の正の相関関係がない。しかし、表 3 に示すように絶対値平均誤差が悪化していないことから、全結合部分で気温と電力の正の相関関係を学習したと考えられる。

次に、具体的な予測値の説明方法を以下の 2 例を用いて述べる。

(a) 予測対象日が平日、正規化した過去の電力実績の入力値が 0.3、正規化した気温の入力値が 0.6 の場合

図 7(b) の①②部分の関係より、電力、気温の疎結合素子から出力層素子に伝達する値 (縦軸の値) が最低値に近い値に近いため、予測電力は平日としては非常に小さい値になると説明できる。また、図から分かるように②は 2 次関数の傾きが無い部分、つまり気温の感度がほとんどない領域であるため、気温の予測誤差の影響は小さいと説明できる。

(b) 予測対象日が平日、正規化した過去の電力実績の入力値が 1.0、正規化した気温の入力値が 1.0 の場合 図 7(b) の③④の関係より、電力、気温の疎結合素子から出力層素子に伝達する値が最大値であるため、予測電力は平日としても大きな値になると説明できる。また、表 4(b) に示すように例 a の日と比較すると出力層素子に伝達する値は、電力の疎結合素子からは 0.95 (①③の縦軸の差) 増加し、気温の疎結合素子からは 1.10 (②④の縦軸の差) 増加しているので、a の日からの予測値の増分の影響比は電力と気温で 95 : 110 であると説明できる。

一方、図 7(a) に示す既提案学習法による構造化ニューラルネットワークでは、気温が 1.0 のときに疎結合素子から出力層素子に伝達する値が最小値 (図中の⑤) になるので、予測対象日の電力が小さな値になるという不適切な説明になってしまう。この原因は、気温と電力の正の相関関係が疎結合ではなく、全結合部分で表現されたからである。表 4 に示すように、例 (a) の日と例 b の日の出力層素子に伝達される値の変化 (表中の |a-b| の行) は、新規提案学習法は疎結合素子合計の方が全結合素子よりも大きいものに対し、既提案学習法では全結合素子の方が大きく、既提案学習法は疎結合で学習すべき独立成分が全結合素子で学習したことを示唆している。

このように新規提案手法は、独立成分を個別に学習するため、既提案手法よりも学習データの特性を適切に表現することが可能であり、予測理由の説明能力に優れている。

例えば最高気温と最低気温の影響度合いを個別に説明したいときには、最高気温と最低気温を別の疎結合に分ける

表 4 例題日における中間層から出力層へ伝達される値

Table 4. Input value of output unit from hidden units at example days.

(a) 既提案学習手法

	電力	気温	フラグ	疎結合計	全結合
a の日	0.71	0.39	0.43	1.53	0.08
b の日	1.81	0.09	0.43	2.33	1.76
a-b	1.10	0.30	0.00	0.80	1.66

(b) 提案学習手法

	電力	気温	フラグ	疎結合計	全結合
a の日	0.07	0.22	1.17	1.46	-0.18
b の日	1.02	1.40	1.17	3.59	-0.01
a-b	0.95	1.10	0.00	2.13	0.17

ことで説明可能である。また、過去 3 日間のそれぞれの気温の影響度合いを説明したいときには、日にちごとに 3 つの疎結合に分けることで説明できる。つまり、構造化ニューラルネットワークは、説明目的に応じて入力因子をグループ分けすることで目的とする説明が可能になる。さらに、各成分の電力への影響度合いを定量的 (MW 換算など) に説明したいときには、シグモイド関数の線形領域を用いることで可能である。

表 3 に予測誤差の比較を示す。新規提案学習法の構造化ニューラルネットワークはバックプロパゲーション法で学習した従来の多層パーセプトロンよりも絶対値平均誤差が優れているが、既提案学習法の構造化ニューラルネットワークには及ばない。新規提案方法は、サブネットワークを個別に学習し合成する手法であるので追加的学習方法の一種であり、既提案学習法は削除的学習方法の一種である。一般に、追加的学習方法よりも、削除的学習方法の方が汎化能力に優れているといわれる。新規提案手法は追加的学習方法の一種であるため、削除的学習方法の一種である既提案学習法と比較すると予測精度の面で及ばなかったと考えられる。

5. あとがき

最大電力予測に対して構造化ニューラルネットワークを適用した。また、構造化ニューラルネットワークの新たな学習方法を提案した。以下に本論分の結論をまとめる。

(1) 新規提案学習法は、既提案学習法よりも学習データの分布を適切に学習することが可能であり、予測値の説明能力に優れていることを確認した。

(2) 新規提案学習法による構造化ニューラルネットワークは、バックプロパゲーション法で学習した従来の多層パーセプトロンと同等以上の予測精度であることを確認した。

(3) 予測精度の面では既提案手法が優れている。説明能力よりも予測精度を重視する場合には既提案手法を、予測精度よりも説明能力を重視する場合には新規提案学習法を使うことが考えられる。

(4) 今後の課題として、運用者にとってより分かりやすい説明方法の検討が上げられる。

(平成14年2月28日受付、平成15年9月16日再受付)

文 献

- (1) 長谷川淳・田中英一:「電力の翌日最大電力需要予測システムの研究開発動向」, 電学論 B, Vol.114, No.9, pp.835-838 (1994-9)
- (2) Y. Ueki, T. Matsui, H. Endo, T. Kato, and R. Araya: "Development of Peak Forecasting System using Neural Networks and Fuzzy Theory", *T. IEE Japan*, Vol.115-B, No.9, pp.1038-1045 (1995) (in Japanese)
植木吉照・松井哲郎・遠藤 弘・加藤龍義・荒家良作:「ニューロ・ファジー応用最大電力システムの開発」, 電学論 B, 115, 9, pp.1038-1045 (1995-9)
- (3) T. Haida, S. Muto, Y. Takahashi, and Y. Ishii: "Peak Load Forecasting Using Multiple Years Data with Trend Data Processing Techniques", *T. IEE Japan*, Vol.117-B, No.8, pp.1101-1108 (1997-8) (in Japanese)
灰田武史・武藤昭一・高橋吉雄・石井康貴:「多年度データのトレンド処理に基づいた最大電力予測」, 電学論 B, 117, 8, pp.1101-1108 (1997-8)
- (4) O. Ishioka, Y. Sato, T. Ishihara, Y. Ueki, T. Matui, and T. Iizaka: "Development of Electric Load Forecasting System using Neural Networks", *T. IEE Japan*, Vol.120-B, No.12, pp.1550-1556 (2000-12) (in Japanese)
石岡 修・佐藤佳彦・石原 徹・植木吉照・松井哲郎・飯坂達也:「NN応用電力需要予測システムの開発」, 電学論 B, 120, 12, pp.1550-1556 (2000-12)
- (5) T. Iizaka and T. Matsui: "Structural learning of neural networks for analysis and knowledge extraction", *T. IEE Japan*, Vol.121-C, No.3, pp.673-680 (2001-3) (in Japanese)
飯坂達也・松井哲郎:「解析と知識の抽出のためのニューラルネットワークの構造化学習」, 電学論 C, 121, 3, pp.673-680 (2001-3)
- (6) T. Iizaka, T. Matsui, and Y. Fukuyama: "Water flow forecasting using analyzable structured neural network", *Proc. of ISAP*, pp.359-364 (2001)
- (7) T. Matsui, T. Iizaka, and Y. Fukuyama: "Peak load forecasting using analyzable structured neural network", *Proc. of IEEE PES Winter Meeting* (2001)
- (8) M. Ishikawa: "A Structural Connectionist Learning Algorithm with Forgetting", *J. Japan. Soc. Artificial Intelligence*, Vol.5, No.5, pp.595-603 (1990) (in Japanese)
石川真澄:「忘却を用いたコネクショニストモデルの構造学習アルゴリズム」, 人工知能学誌, 5, No.5, pp.595-603 (1990)
- (9) T. Takahashi and R. Tokunaga: "Removing Redundancy of Multi-Layer Perceptron Using Superposed Energy Function", *IEICE*, Vol.J80-D-II, No.9, pp.2532-2540 (1997-9) (in Japanese)
高橋隆史・徳永隆治:「重畳エネルギー関数による多層パーセプトロンの冗長性削除」, 通信学論 D-II, J80-D-II, 9, pp.2532-2540 (1997-9)
- (10) T. Masuda, Y. Fujii, and H. Ikeya: "Compact Structuring Hierarchical Neural Networks by Combining Extra Hidden Units", *SICE*, Vol.28, No.4, pp.519-527 (1992) (in Japanese)
増田達也・藤井善行・池谷治彦・相部仁子:「隠れユニットの合成に

よる階層型ニューラルネットワークのコンパクト構造化」, 計測自動制御学論, 28, No.4, pp.519-527 (1992)

- (11) M. Fukumi and N. Akamatsu: "A Method to Extract Rules from Neural Networks Formed Using Evolutionary Algorithms", *T. IEE Japan*, Vol.120-C, No.4, pp.529-535 (2000-4) (in Japanese)
福見 稔・赤松則男:「進化的アルゴリズムにより構造化されたニューラルネットワークからのルール抽出の一方法」, 電学論 C, 120, 4, pp.529-535 (2000-4)
- (12) 森 啓之・小林秀典:「最適化ファジイモデリング手法を用いた翌日最大電力負荷予測」, 電気学会電力技術研資, PE-95-45 (1995)
- (13) H. Mori and N. Kosemura: "ANN Based Load Forecasting with Rule Discovery", 2000 National Convention Record IEE Japan, 6-021 (2000) (in Japanese)
森 啓之・小瀬村紀之:「ルール発見に基づくニューラルネットワークによる短期電力負荷予測法」, 平成12年電気学会全国大会, 6-021 (2000)

飯坂達也(正員) 1969年5月20日生。1994年3月埼玉大学理工学研究科電気工学専攻博士前期課程修了。同年4月富士電機(株)に入社。現在に至る。主として電力システムのインテリジェントシステムに関する研究に従事。



松井哲郎(正員) 1965年3月31日生まれ。1988年3月横浜国立大学工学部情報工学科卒業。同年4月富士電機(株)に入社。現在に至る。主として電力システムのエキスパートシステム、インテリジェントシステムに関する研究に従事。



福山良和(正員) 1962年7月26日生。1987年3月早稲田大学院理工学研究科修士課程修了。同年4月富士電機(株)入社。1993~94年米国コーネル大学客員研究員。主として、電力システムのインテリジェントシステム適用、制御及び系統解析に関する研究に従事。工学博士。IEEE 会員。

